Progetto di statistica
PCA e Regressione Lineare

Università di Pisa

Corso di Laurea di Artificial Intelligence and Data Engineering

Emilio Paolini 54485

Indice

1 Introduzione al problema **1**

2 Dati **1**
2.1 Raccolta 1
2.2 Interpretazione dei dati 3
2.3 Matrice Scatter Plot e correlazioni 3

3 PCA **5**

4 Regressione lineare **5**

5 Analisi dei residui **6**

6 Autovalutazione del modello **8**

7 Conclusioni **9**

1 Introduzione al problema

Il problema si colloca nell'ambito musicale, in particolare l'analisi, dal punto di vista di una casa discografica, del successo dei brani. É un fatto noto che le canzoni con maggiore energia abbiano maggiore probabilità di diventare popolari [1] [2]. La domanda che ci poniamo è quindi la seguente: è possibile, attraverso varie caratteristiche di un brano, stimare la sua energia, e quindi la sua probabilità di successo? Lo studio è stato effettuato tramite i dati delle canzoni appartenenti alla playlist "Top Tracks of 2018" del noto servizio di streaming musicale Spotify. Nel seguito verrà spiegato come è stato possibile ottenere questi dati e le analisi che sono state fatte. Infine verranno presentate delle conclusioni basate sullo studio effettuato.

2 Dati

2.1 Raccolta

I dati sono stati ottenuti, tramite uno script Python, da Spotify. Tale servizio infatti mette a disposizione delle API (Application Programming Interface) per recuperare varie informazioni su canzoni, playlist, artisti presenti sulla piattaforma. Per poter utilizzare tali funzioni è però necessario avere un Token, ossia un gettone che permette l'accesso ai dati per un periodo di tempo limitato (infatti quando il token scade sarà necessario chiederlo uno nuovo). Per ottenere tale gettone è necessario per prima cosa collegarsi al seguente link: `https://developer.spotify.com/console/get-audio-features-track/`. La pagina si presenta come mostrato in figura 1.

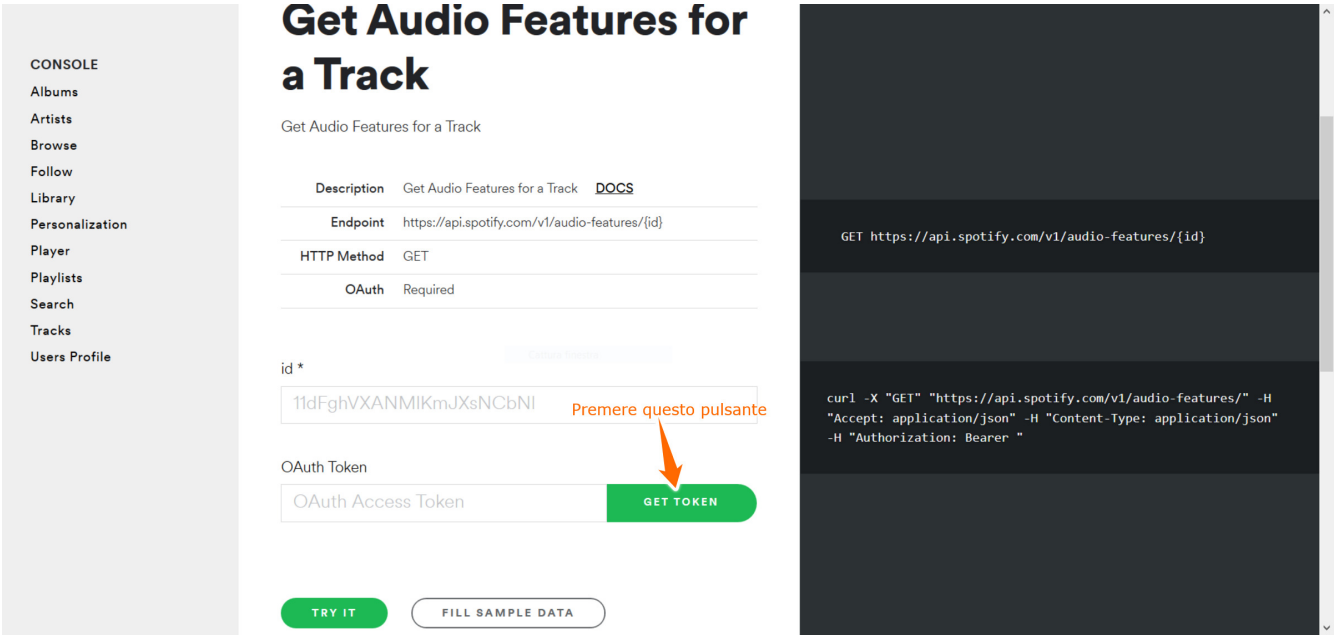

Figura 1: Come ottenere il token.

Il passo successivo è premere il pulsante "GET TOKEN" come mostrato in figura 1. Si aprirà il popup mostrato in figura 2.

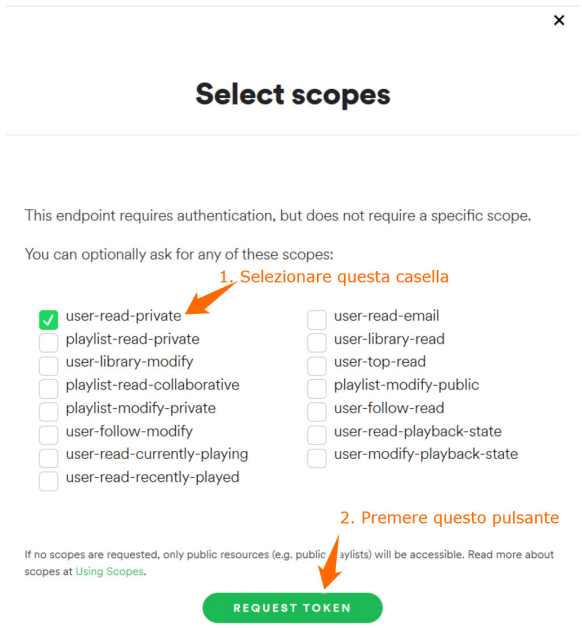

Figura 2: Selezionare lo scopo per cui verrà usato il token.

In esso sarà necessario selezionare la prima casella e infine cliccare sul pulsante "REQUEST TOKEN". Fatto ciò, la pagina si aggiornerà in modo automatico e nel campo "OAuth Token" ci sarà il token da utilizzare nello script python. Per rendere funzionante lo script sarà necessario copiare ed incollare il nuovo token nella variabile TOKEN presente nello script, sostituendo il contenuto della stringa "NUOVO TOKEN QUI" con quella appena copiata:

```
TOKEN = "Bearer "+"NUOVO TOKEN QUI"
```

L'esecuzione del codice contenuto nello script python "scriptDati.py" produrrà un file di nome "tabella.csv", nella stessa directory in cui è presente lo script, contenente i dati su cui verranno effettuate le analisi.

2.2 Interpretazione dei dati

I dati estratti, come già detto in precedenza, provengono dalla playlist di Spotify "Top Tracks of 2018", visibile a questo link: `https://open.spotify.com/playlist/37i9dQZF1DX1HUbZS4LEyL`. In particolare, per ogni canzone (corrispondente ad un'osservazione), sono stati estratti i seguenti dati:

- Length: indica la durata della canzone in millisecondi.
- Acousticness: indica quanto è acustico un brano. Assume valori compresi tra 0 e 1.
- Danceability: indica quanto è ballabile un brano. Assume valori compresi tra 0 e 1.
- Energy: indica l'energia di un brano. Assume valori compresi tra 0 e 1.
- Liveness: rileva la presenza di un pubblico nel brano. All'aumentare di questo valore, aumenta la probabilità che il brano sia stato registrato live. Assume valori tra 0 e 1.
- Loudness: indica la rumorosità del brano in decibel (dB).
- Speechiness: rileva la presenza di parole nel brano.
- Valence: descrive la positività musicale della canzone. Brani che hanno un valore alto di valence sono più felici/positivi. Assume valori tra 0 e 1.
- Tempo: indica il tempo complessivo di un brano in BPM (Battiti per minuto). Il tempo di una canzone indica il suo ritmo.

Nella raccolta dei dati sono già state effettuate le operazioni di data pre-processing, escludendo gli attributi non utili ai fini delle analisi, tra cui: Name, id, uri, track_href, analysis_url. Sono stati esclusi i fattori categorici.

2.3 Matrice Scatter Plot e correlazioni

Valutiamo per prima cosa le correlazioni tra i vari fattori dei dati:

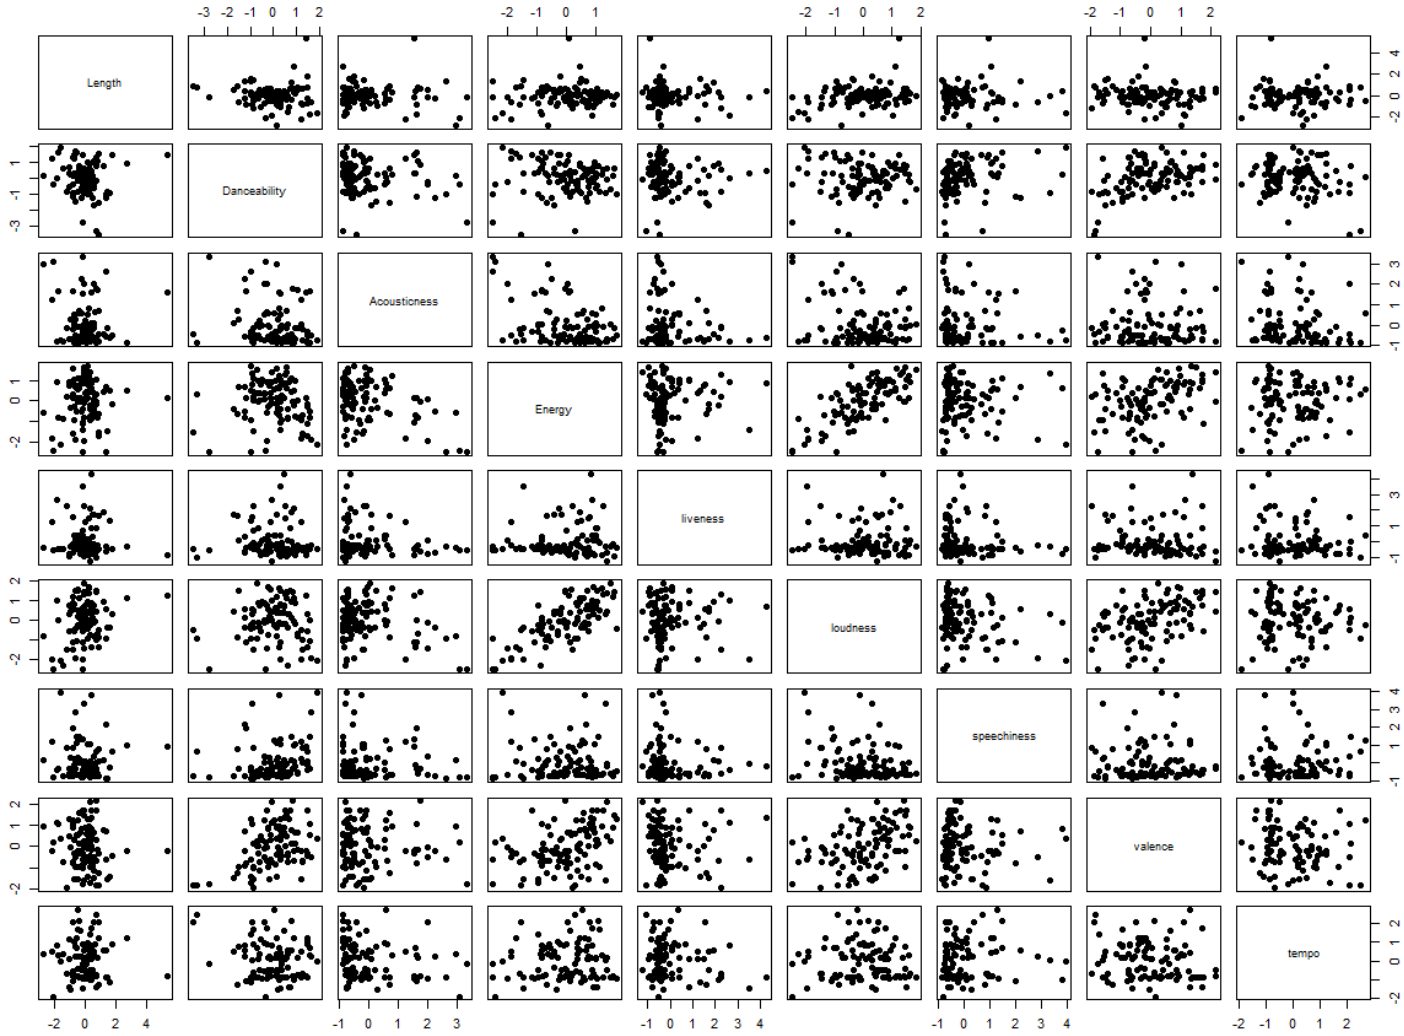

Figura 3: Matrice Scatter Plot.

Sembra esserci una dipendenza lineare tra Energy e loudness. Anche tra Energy e valence sembra esserci una dipendenza lineare, molto più "deviata". Dal punto di vista quantitativo otteniamo il seguente risultato:

	Length	Danceability	Acousticness	Energy	liveness	loudness	speechiness	valence	tempo
Length	1.00	-0.07	-0.07	0.07	-0.05	0.27	-0.01	-0.14	0.01
Danceability	-0.07	1.00	-0.14	-0.07	-0.04	0.02	0.23	0.41	-0.19
Acousticness	-0.07	-0.14	1.00	-0.42	-0.16	-0.27	-0.08	-0.03	-0.16
Energy	0.07	-0.07	-0.42	1.00	0.06	0.73	-0.07	0.39	0.06
liveness	-0.05	-0.04	-0.16	0.06	1.00	0.01	-0.10	-0.04	-0.11
loudness	0.27	0.02	-0.27	0.73	0.01	1.00	-0.25	0.41	-0.03
speechiness	-0.01	0.23	-0.08	-0.07	-0.10	-0.25	1.00	-0.05	0.10
valence	-0.14	0.41	-0.03	0.39	-0.04	0.41	-0.05	1.00	-0.15
tempo	0.01	-0.19	-0.16	0.06	-0.11	-0.03	0.10	-0.15	1.00

Figura 4: Correlazioni tra i fattori.

Sembrerebbe cioè che ad influenzare maggiormente il fattore Energy siano loudness, acousticness e valence.

3 PCA

Proviamo per prima cosa ad effettuare un'analisi delle componenti principali, per provare a ridurre il numero di fattori. Dal summary della PCA otteniamo l'output mostrato in figura 5.

```
Importance of components:
                          Comp.1    Comp.2    Comp.3    Comp.4    Comp.5     Comp.6     Comp.7     Comp.8     Comp.9
Standard deviation     1.5026337 1.2276719 1.1263617 1.0491274 0.9981366 0.81358855 0.78632283 0.56039223 0.43012647
Proportion of Variance 0.2534128 0.1691558 0.1423895 0.1235318 0.1118156 0.07429027 0.06939434 0.03524573 0.02076417
Cumulative Proportion  0.2534128 0.4225686 0.5649581 0.6884899 0.8003055 0.87459575 0.94399010 0.97923583 1.00000000
```

Figura 5: Summary PCA.

Notiamo che la prima componente principale contiene una proporzione di varianza del 25%. Ciò non è un buon risultato in quanto per arrivare ad una proporzione di varianza di circa l'80% abbiamo bisogno delle prime 5 componenti principali, come mostra la figura 6.

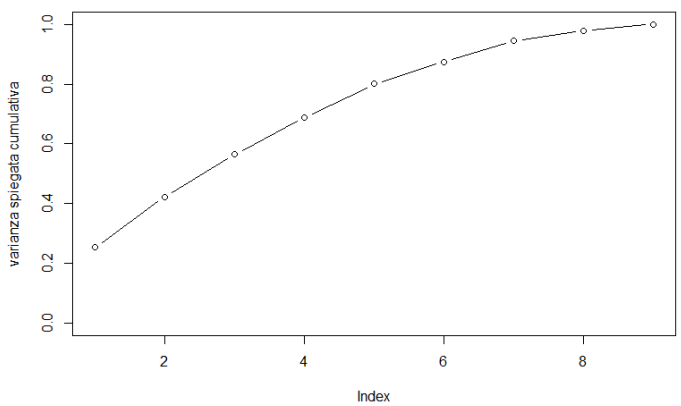

Figura 6: Andamento varianza spiegata con componenti principali.

I risultati appena ottenuti scoraggiano ad usare la PCA per analizzare il problema. Nei paragrafi successivi verranno svolte le analisi utilizzando la regressione lineare e ne verranno analizzati i risultati.

4 Regressione lineare

Proviamo ora ad effettuare una regressione lineare multivariata, con fattore di uscita Energy. I coefficienti dei fattori, con i relativi p-value e il p-value del modello che otteniamo sono mostrati in figura 7.

```
Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)  -2.363e-16  6.055e-02   0.000 1.000000
Length       -9.875e-02  6.622e-02  -1.491 0.139353
Danceability -2.365e-01  7.261e-02  -3.257 0.001581 **
Acousticness -2.612e-01  6.776e-02  -3.855 0.000216 ***
liveness      2.191e-02  6.297e-02   0.348 0.728709
loudness      6.374e-01  7.916e-02   8.052 2.99e-12 ***
speechiness   1.303e-01  6.628e-02   1.966 0.052397 .
valence       2.151e-01  7.891e-02   2.726 0.007684 **
tempo         2.195e-02  6.468e-02   0.339 0.735122
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6055 on 91 degrees of freedom
Multiple R-squared:  0.663,     Adjusted R-squared:  0.6334
F-statistic: 22.38 on 8 and 91 DF,  p-value: < 2.2e-16
```

Figura 7: Coefficienti dei fattori, p-value fattori, p-value modello.

Otteniamo una varianza spiegata del 66.3% ed una varianza spiegata aggiustata del 63.34%. Il p-value è molto piccolo, minore di 0.05, il che ci indica che abbiamo ottenuto un modello statisticamente significativo. Sono dei valori accettabili ma il modello sembra troppo complesso, in quanto tiene in considerazioni

troppi fattori. Riduciamo il numero di essi, partendo da quello con p-value più alto, fino a quando non abbiamo una drastica riduzione della varianza spiegata. I fattori rimossi e l'andamento della varianza spiegata e della varianza spiegata aggiustata sono descritti dai seguenti grafici:

Varianza Spiegata	Varianza Spiegata Aggiustata	Fattori Rimossi
66.30%	63.34%	-
66.26%	63.69%	tempo
66.23%	64.05%	tempo, liveness
65.37%	63.53%	tempo, liveness, Length
64.05%	62.54%	tempo, liveness, Length, speechiness
60.36%	59.13%	tempo, liveness, Length, speechiness, Danceability

Figura 8: Andamento varianza spiegata e varianza spiegata aggiustata.

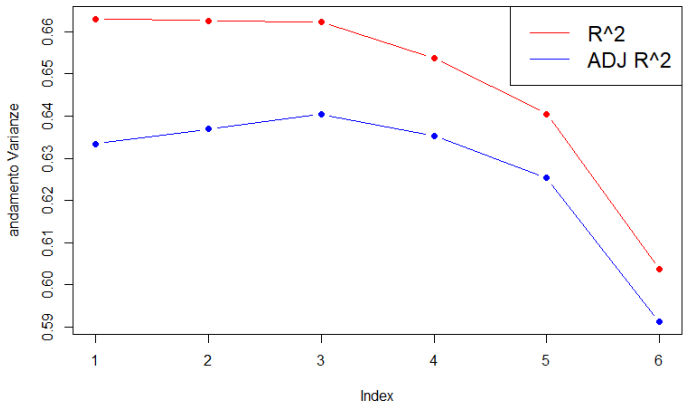

Figura 9: Grafico andamento varianza spiegata e varianza spiegata aggiustata.

Ci possiamo fermare al fattore Length, in quanto continuando ad eliminare abbiamo una diminuzione di varianza spiegata non trascurabile, segnale che indica di fermarci nel ridurre i fattori perchè stiamo perdendo struttura. Comunque abbiamo ottenuto un modello che ha il 65.37% di varianza spiegata ed una varianza spiegata aggiusta del 63.53% ma dipendente da soli 5 fattori, contro gli 8 del primo. I coefficienti dei fattori, con i relativi p-value e il p-value del modello sono visibili in figura 10.

```
Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)  -2.553e-16  6.039e-02   0.000 1.000000
Danceability -2.470e-01  7.078e-02  -3.490 0.000737 ***
Acousticness -2.743e-01  6.506e-02  -4.215 5.73e-05 ***
loudness      5.925e-01  7.354e-02   8.057 2.43e-12 ***
speechiness   1.233e-01  6.511e-02   1.893 0.061446 .
valence       2.464e-01  7.554e-02   3.262 0.001542 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6039 on 94 degrees of freedom
Multiple R-squared:  0.6537,    Adjusted R-squared:  0.6353
F-statistic: 35.49 on 5 and 94 DF,  p-value: < 2.2e-16
```

Figura 10: Coefficienti dei fattori, p-value fattori, p-value modello ridotto.

Otteniamo lo stesso p-value del modello completo, il che ci dice che il nostro modello è ancora statisticamente significativo, pur tenendo conto di un numero minore di fattori.

5 Analisi dei residui

Come prima operazione nell'analisi dei residui vediamo la loro distribuzione nel piano e cerchiamo di capire se presentano o meno struttura.

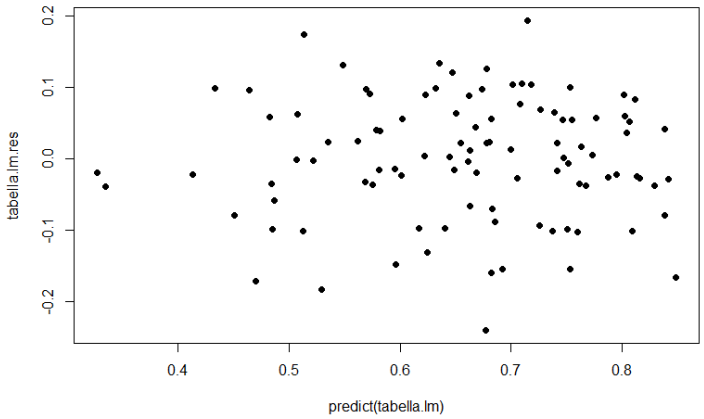

Figura 11: Plot dei residui

Dalla figura 11 è possibile notare come i residui siano distribuiti in modo quasi uniforme, il che ci fa ben sperare che il modello catturi tutta la struttura del problema. Come secondo passo verifichiamo l'ipotesi di gaussianità dei residui, la quale, se confermata, ci indica che i residui sono distribuiti in maniera casuale. Analizziamo il problema prima da un punto di vista grafico:

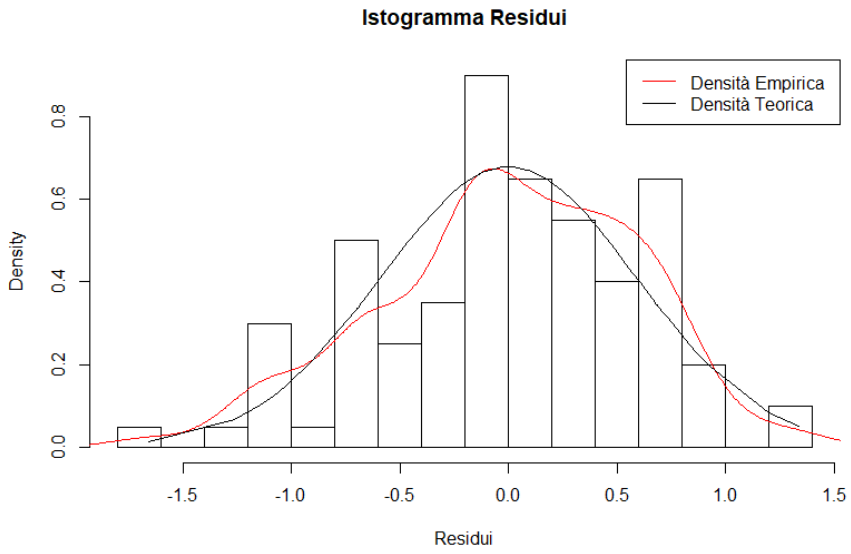

Figura 12: Istogramma della distribuzione dei residui.

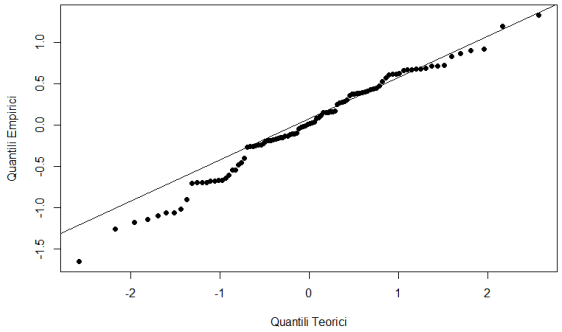

Figura 13: Grafico quantile-quantile.

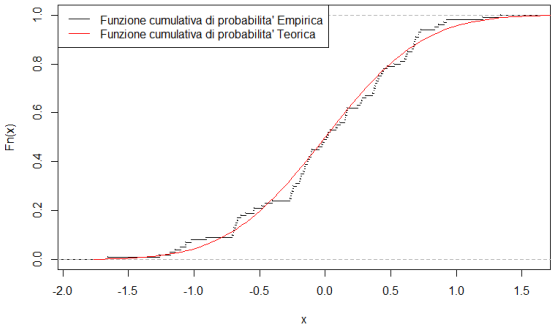

Figura 14: Funzione cumulativa di probabilità

ed infine da un punto di vista quantitativo, attraverso il test di Shapiro-Wilk:

```
        Shapiro-Wilk normality test

data:  tabella.lm.r
W = 0.98321, p-value = 0.2345
```

Figura 15: Risultato del test di Shapiro-Wilk.

Dall'analisi del plot quantile-quantile, vediamo che il grafico è molto vicino ad una retta e ciò supporta l'ipotesi di normalità sui residui. Anche la densità empirica dei residui è molto vicina a quella teorica. È inoltre possibile notare che l'andamento della funzione cumulativa di probabilità segue l'andamento teorico. Infine il p-value del test di Shapiro-Wilk, di valore 0.2345>0.05, ci indica che possiamo accettare l'ipotesi nulla di tale test, ossia quella di normalità dei residui. Altri due valori che ci aiutano nell'analisi dei residui sono Kurtosis e Skewness. Il primo risulta pari a 2.75, indicando che la distribuzione dei residui si avvicina ad una distribuzione normale (che ha valore di Kurtosis pari a 3). La Skewness è pari a 0.34 (più si avvicina a 0 e più la distribuzione è simmetrica). Possiamo quindi concludere che i residui hanno una distribuzone simmetrica sul piano, non contenente struttura.

6 Autovalutazione del modello

Per valutare il modello ottenuto usiamo i dati riguardanti i brani della playlist "Top 100 Tracks of 2014 - Global", visibile al seguente link : `https://open.spotify.com/playlist/0KzjapF1zYpPYARZFeBnYm`. In figura 16 è possibile vedere da un punto di vista grafico come si comporta il modello nel predire 50 brani estratti casualmente da tale playlist.

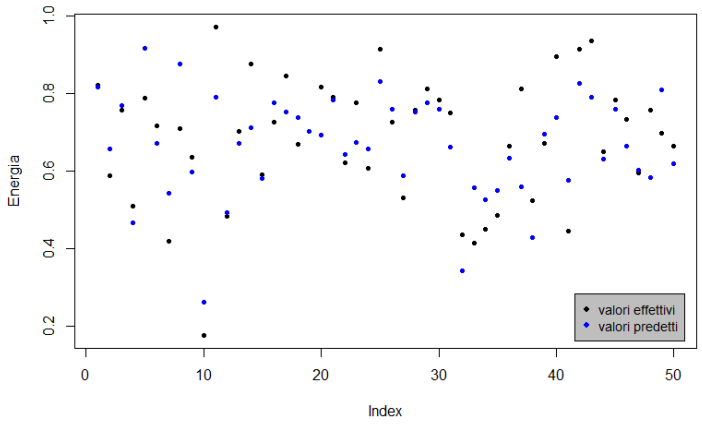

Figura 16: Valori reali vs Valori Predetti.

Non sembrerebbe essere un risultato negativo, in quanto i valori predetti nella maggior parte dei casi si avvicinano molto a quelli effettivi. Comunque per ottenere risultati statisticamente significativi eseguiamo le seguenti operazioni 50 volte: costruiamo il nostro modello con 80 campioni casuali della playlist "Top Tracks of 2018" (playlist usata come Training Set). Fatto ciò, estraiamo 20 brani, in modo casuale dalla playlist "Top 100 Tracks of 2014 - Global" (playlist usata come Test Set), di cui proveremo a calcolarne l'energia. L'errore medio che otteniamo è del 2.05%, con una deviazione standard pari a 0.64%. Una visualizzazione grafica degli intervalli di previsione e di confidenza ottenuti su 5 campioni estratti casualmente dal Test Set sono visibili in figura 17.

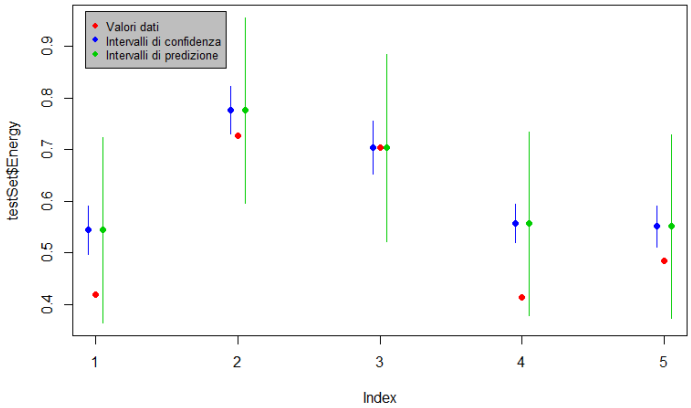

Figura 17: Intervalli di confidenza e di predizione per 5 campioni estratti casualmente dal Test Set.

Possiamo quindi essere soddisfatti del modello ottenuto, il quale si comporta bene nella predizione e sembra essere capace a generalizzare il problema, non soffrendo quindi di overfitting.

7 Conclusioni

Il modello finale che otteniamo è il seguente:

$$\begin{aligned} Energy = &-2.553 \times 10^{-16} - 0.247 \times Danceability - 0.274 \times Acousticness \\ &+0.593 \times Loudness + 0.123 \times Speechiness + 0.246 \times Valence \end{aligned}$$

Abbiamo esaminato i residui di tale modello ed essi non hanno struttura, favorendo l'ipotesi che il nostro modello catturi l'intera struttura del problema. Inoltre ha una varianza spiegata pari al 65.37%. La parte di variazione del problema che il modello non riesce a spiegare è probabilmente dovuta al rumore, che non è possibile eliminare. Possiamo quindi ritenere tale modello affidabile ed usarlo per delle previsioni, come mostrato nel paragrafo 6.
Quali sono le informazioni che possiamo ricavare da tale modello? Esaminando i coefficienti dei fattori, vediamo che per aumentare l'energia di una canzone, e quindi la sua probabilità di avere successo, dobbiamo aumentare Loudness, Speechiness e Valence e ridurre Danceability e Acousticness. Quindi le canzoni che presentano un maggior numero di parole, sono più rumorose e più positive sono le più popolari.

Elenco delle figure

1 Come ottenere il token. 2
2 Selezionare lo scopo per cui verrà usato il token. 2
3 Matrice Scatter Plot. 4
4 Correlazioni tra i fattori. 4
5 Summary PCA. 5
6 Andamento varianza spiegata con componenti principali. 5
7 Coefficienti dei fattori, p-value fattori, p-value modello. 5
8 Andamento varianza spiegata e varianza spiegata aggiustata. 6
9 Grafico andamento varianza spiegata e varianza spiegata aggiustata. 6
10 Coefficienti dei fattori, p-value fattori, p-value modello ridotto. 6
11 Plot dei residui 7
12 Istogramma della distribuzione dei residui. 7
13 Grafico quantile-quantile. 7
14 Funzione cumulativa di probabilità 7
15 Risultato del test di Shapiro-Wilk. 8
16 Valori reali vs Valori Predetti. 8
17 Intervalli di confidenza e di predizione per 5 campioni estratti casualmente dal Test Set. 9

Riferimenti bibliografici

[1] What makes a song likeable `https://towardsdatascience.com/what-makes-a-song-likeable-dbfdb7abe404`

[2] What makes a hit - `https://www8.gsb.columbia.edu/articles/projects/what-makes-a-hit/#explorer-intro`