Progetto di statistica
Classificazione e clustering

Università di Pisa

Corso di Laurea di Artificial Intelligence and Data Engineering

Emilio Paolini 54485

Indice

1 Introduzione al problema **1**

2 Dati **1**
2.1 Raccolta 1
2.2 Interpretazione dei dati 2
2.3 Correlazioni 3

3 Classificazione **3**
3.1 Classificazione mediante regressione logistica 3
3.2 Classificazione mediante analisi discriminante lineare 5
3.3 Confronto tra classificatori 5

4 Conclusioni **6**

1 Introduzione al problema

Il problema riguarda la divisione di brani per genere musicale. Molti servizi di streaming musicale, al momento dell'iscrizione chiedono quali sono i generi musicali preferiti dell'utente per poi mostrarli varie canzoni appartenenti a tali generi. Quindi, ponendoci dal punto di vista di una piattaforma di streaming musicale, ci chiediamo: é possibile effettuare una classificazione automatica delle canzoni in base alle proprietá musicali di essa, cosí da poter mostrare agli utenti le canzoni dei loro generi preferiti? Classificare le canzoni in questo modo potrebbe anche essere utile ad organizzare per genere le varie playlist presenti sul servizio.

2 Dati

2.1 Raccolta

I dati sono stati ottenuti, tramite uno script Python (simile a quello del primo progetto), da Spotify. Tale servizio infatti mette a disposizione delle API (Application Programming Interface) per recuperare varie informazioni su canzoni, playlist, artisti presenti sulla piattaforma. Per poter utilizzare tali funzioni è però necessario avere un Token, ossia un gettone che permette l'accesso ai dati per un periodo di tempo limitato (infatti quando il token scade sarà necessario chiederlo uno nuovo). Per ottenere tale gettone è necessario per prima cosa collegarsi al seguente link: https://developer.spotify.com/console/get-audio-features-track/. La pagina si presenta come mostrato in figura 1.

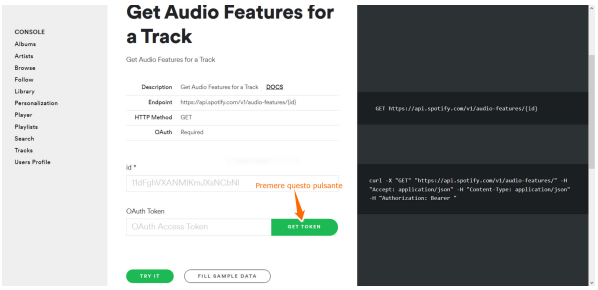

Figura 1: Come ottenere il token.

Il passo successivo è premere il pulsante "GET TOKEN" come mostrato in figura 1. Si aprirà il popup

mostrato in figura 2.

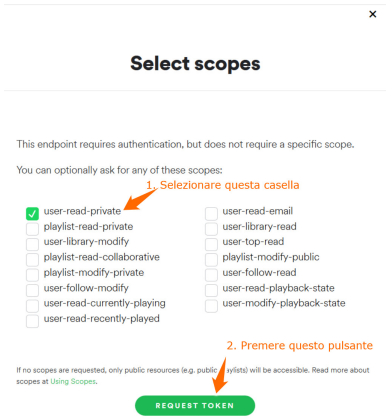

Figura 2: Selezionare lo scopo per cui verrà usato il token.

In esso sarà necessario selezionare la prima casella e infine cliccare sul pulsante "REQUEST TOKEN". Fatto ciò, la pagina si aggiornerà in modo automatico e nel campo "OAuth Token" ci sarà il token da utilizzare nello script python. Per rendere funzionante lo script sarà necessario copiare ed incollare il nuovo token nella variabile TOKEN presente nello script, sostituendo il contenuto della stringa "NUOVO TOKEN QUI" con quella appena copiata:

```
TOKEN = "Bearer "+"NUOVO TOKEN QUI"
```

L'esecuzione del codice contenuto nello script python "scriptDati.py" produrrà un file di nome "tabella.csv", nella stessa directory in cui è presente lo script, contenente i dati su cui verranno effettuate le analisi. I dati provengono da 6 playlist presenti su Spotify, ognuna delle quali contiene 100 canzoni di uno specifico genere. Le playlist usate sono le seguenti:

- "Top 100 Metal Tracks on Spotify": playlist contenente 100 canzoni Heavy Metal. Link a Spotify.
- "Hot Acoustics": playlist contenente 100 canzoni Acoustics. Link a Spotify.
- "100 Gretest Rock Song Ever": playlist contenenete 100 canzoni Rock. Link a Spotify.
- "Best POP songs of 2019": playlist contenente 100 canzoni Pop. Link a Spotify.
- "Best of the Best of Jazz": playlist contenente 100 canzoni Jazz. Link a Spotify.
- "Trap Music Hits 2019": playlist contenete 100 canzoni Trap. Link a Spotify.

2.2 Interpretazione dei dati

Per ogni canzone (corrispondente ad un'osservazione), sono stati estratti i seguenti dati:

- Key: indica la chiave della canzone.
- time_signature: fornisce un'indicazione sul tempo della canzone.
- Mode: indica la modalità della canzone (se minore o maggiore).
- Length: indica la durata della canzone in millisecondi.

- Acousticness: indica quanto è acustico un brano. Assume valori compresi tra 0 e 1.
- Danceability: indica quanto è ballabile un brano. Assume valori compresi tra 0 e 1.
- Energy: indica l'energia di un brano. Assume valori compresi tra 0 e 1.
- Liveness: rileva la presenza di un pubblico nel brano. All'aumentare di questo valore, aumenta la probabilità che il brano sia stato registrato live. Assume valori tra 0 e 1.
- Loudness: indica la rumorosità del brano in decibel (dB).
- Speechiness: rileva la presenza di parole nel brano.
- Valence: descrive la positività musicale della canzone. Brani che hanno un valore alto di valence sono più felici/positivi. Assume valori tra 0 e 1.
- Tempo: indica il tempo complessivo di un brano in BPM (Battiti per minuto). Il tempo di una canzone indica il suo ritmo.

Nella raccolta dei dati è stato aggiunto, automaticamente dallo script, un ulteriore attributo per ogni canzone di nome "Genere", rappresentante il genere musicale del brano. Per questioni di comodità ogni genere è stato mappato in un numero all'interno dell'attributo "Classe".

2.3 Correlazioni

Valutiamo le correlazioni tra i vari fattori e la classe, per vedere quali sono gli attributi che influenzano maggiormente il genere musicale:

	Length	Key	Mode	time_signature	Danceability	Acousticness	Energy	liveness	loudness	speechiness	valence	tempo	Classe
Length	1.00	-0.02	-0.02	-0.07	-0.35	-0.12	0.17	0.17	-0.07	-0.08	-0.07	-0.01	-0.24
Key	-0.02	1.00	-0.08	0.02	0.00	-0.02	0.02	0.02	0.07	0.01	-0.01	-0.06	-0.07
Mode	-0.02	-0.08	1.00	0.00	0.03	0.00	0.00	0.03	-0.03	0.01	0.04	-0.06	-0.07
time_signature	-0.07	0.02	0.00	1.00	0.11	-0.09	0.15	0.01	0.14	0.02	0.06	-0.08	0.00
Danceability	-0.35	0.00	0.03	0.11	1.00	0.11	-0.21	-0.25	0.12	0.02	0.39	-0.10	0.36
Acousticness	-0.12	-0.02	0.00	-0.09	0.11	1.00	-0.85	-0.20	-0.60	-0.26	0.06	-0.24	0.02
Energy	0.17	0.02	0.00	0.15	-0.21	-0.85	1.00	0.24	0.71	0.31	-0.06	0.26	-0.08
liveness	0.17	0.02	0.03	0.01	-0.25	-0.20	0.24	1.00	0.07	0.12	-0.16	0.08	-0.07
loudness	-0.07	0.07	-0.03	0.14	0.12	-0.60	0.71	0.07	1.00	0.21	0.00	0.20	0.04
speechiness	-0.08	0.01	0.01	0.02	0.02	-0.26	0.31	0.12	0.21	1.00	-0.16	0.15	0.16
valence	-0.07	-0.01	0.04	0.06	0.39	0.06	-0.06	-0.16	0.00	-0.16	1.00	0.01	0.02
tempo	-0.01	-0.06	-0.06	-0.08	-0.10	-0.24	0.26	0.08	0.20	0.15	0.01	1.00	0.05
Classe	-0.24	-0.07	-0.07	0.00	0.36	0.02	-0.08	-0.07	0.04	0.16	0.02	0.05	1.00

Figura 3: Correlazioni tra i vari fattori.

Sembrerebbe che ad influenzare maggiormente il genere musicale di una canzone, sia in positivo che in negativo, siano i seguenti fattori: Danceability, Length e Speechiness. Se ci pensiamo questo risultato era prevedibile, in quanto prendendo a confronto ad esempio il Pop con l'Heavy Metal, sappiamo che le canzoni appartenenti al primo genere contengono molte piú parole rispetto a quelle del secondo, e quindi il fattore speechiness ci aiuta a differenziare i vari brani in questo senso. Ragionamenti simili possono essere applicati agli altri fattori.

3 Classificazione

3.1 Classificazione mediante regressione logistica

Per effettuare una classificazione mediante regressione logistica, essendo la nostra classificazione non binaria, dobbiamo svolgere una classificazione una contro tutti, ripetendo la costruzione e l'analisi

del classificatore per un numero di volte pari al numero di classi. Prendiamo come riferimento la classificazione Heavy Metal contro tutti. Osservando l'accuratezza, pari al 92%, ci potremmo ritenere soddisfatti.
Ma, facendo una semplice osservazione, scopriamo che le cose non funzionano come dovrebbero. Il dataset é fortemente sbilanciato quando eseguiamo la classificazione binaria: abbiamo infatti 100 istanze appartenenti alla classe 1 (Heavy Metal), 500 istanze appartenenti alla classe 0. L'alta accuratezza potrebbe essere dovuta ad un classificatore che classifica molto bene le istanze appartenenti alla classe 0 , ma non si comporta altrettanto bene sulla classe Heavy Metal. Infatti, poniamo per ipotesi di costruire un classificatore che classifica ogni istanza sempre come appartenente alla classe 0. In questo caso otterremmo comunque un'accuratezza molto alta, infatti il nostro classificatore sbaglierebbe solamente 100 volte su 600 (nell'ipotesi che il dataset sia fortemente sbilanciato, con un rapporto tra classe 1 e classe 0 pari a 1 su 6), ottenendo un valore di accuratezza di circa l'80%. Per scoprire se ció accade, osserviamo la matrice di confusione:

	actual 1	actual 0
predicted 1	70	18
predicted 0	30	482

Figura 4: Matrice di confusione.

Notiamo che il classificatore ottenuto classifica correttamente 70 istanze su 100 della classe 1, mentre sbaglia solamente 18 istanze su 500 della classe 0. Ció falsifica il valore dell'accuratezza ottenuto precedentemente e conferma il nostro dubbio. Per ottenere dei risultati migliori sulla classe Heavy Metal, proviamo a cambiare soglia di accettazione e vedere come cambia la matrice di confusione.

	actual 1	actual 0
predicted 1	73	29
predicted 0	27	471

Figura 5: Matrice di confusione con soglia di accettazione 0.4, accuratezza: 91%

	actual 1	actual 0
predicted 1	79	38
predicted 0	21	462

Figura 6: Matrice di confusione con soglia di accettazione 0.3, accuratezza: 90%

	actual 1	actual 0
predicted 1	85	60
predicted 0	15	440

Figura 7: Matrice di confusione con soglia di accettazione 0.2, accuratezza: 88%

	actual 1	actual 0
predicted 1	89	98
predicted 0	11	402

Figura 8: Matrice di confusione con soglia di accettazione 0.1, accuratezza: 82%

I risultati appena ottenuti mostrano come la soglia di accettazione di 0.2 sia quella che garantisce il miglior risultato. Otteniamo un'accuratezza minore di quella con soglia pari a 0.5, ma il classificatore si comporta molto meglio sulla classe di riferimento. La minore accuratezza é dovuta al fatto che il modello ottenuto classifichi 60 canzoni, appartenenti alla classe 0, come appartenenti alla classe 1.
Ció é comunque un risultato accettabile, in quanto dobbiamo tenere conto del fatto che stiamo parlando di canzoni. Infatti alcune di esse potrebbero essere state classificate da Spotify come generi diversi dall'Heavy Metal, pur avendo notevoli somiglianze con tale genere. Inoltre molti brani non appartengono ad un solo genere musicale, ma anzi sono un mix di vari generi.
Le stesse considerazioni sono state fatte eseguendo le classificazioni una contro tutti per ogni genere presente nel dataset, ottenendo le varie soglie ottime, visibili in figura 9.

Classe 1	Accuratezza	Soglia ottima
Heavy Metal	88%	0.2
Acoustic	92%	0.3
Rock	85%	0.25
Pop	81%	0.25
Jazz	84%	0.2
Trap	92%	0.3

Figura 9: Tabella riassuntiva delle varie classificazioni una contro tutti

3.2 Classificazione mediante analisi discriminante lineare

Eseguiamo adesso una classificazione mediante analisi discriminante. Una volta ottenuto il classificatore, vediamo nelle seguenti figure un confronto della capacitá distintiva tra l'analisi discriminante e la PCA.

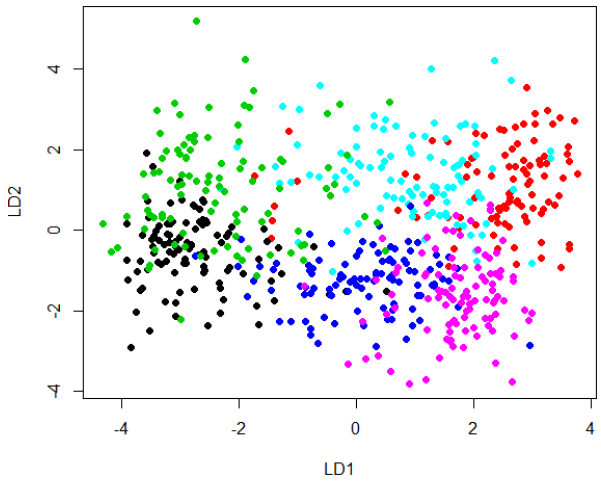

Figura 10: Capacitá distintiva analisi discr.

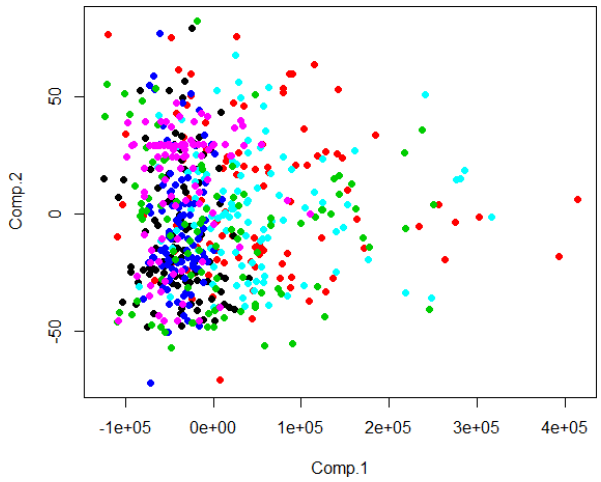

Figura 11: Capacitá distintiva PCA.

Osserviamo come l'analisi discriminante fornisca risultati molto migliori della PCA.

3.3 Confronto tra classificatori

Effettuiamo adesso un confronto tra la classificazione mediante regressione logistica e quella tramite analisi discriminante al fine di scegliere la migliore. Per effettuare tale confronto, dividiamo il dataset in training set e test set. Il primo verrá utilizzato per la costruzione dei modelli (6 modelli di classificazione una contro tutti ottenuti tramite regressione logistica e un modello di classificazione ottenuto tramite analisi discriminante), mentre il secondo sará utilizzato per valutare l'accuratezza dei modelli. Per quanto riguarda i 6 modelli ottenuti con la regressione logistica, per determinare a quale classe essi associano l'osservazione, otteniamo le probabilitá di assegnazione alle varie classi e scegliamo quella con probabilitá maggiore. Il seguente frammento di codice mostra come sono state ottenute le probabilitá di assegnazione e come é stato effettuato il conteggio sull'accuratezza:

```
matriceProbabilita = cbind(tabella.glm.pHeavyMetal,tabella.glm.pAcoustic,tabella.glm.pRock,
                           tabella.glm.pPop,tabella.glm.pJazz,tabella.glm.pJazz)
vettoreIndiceMassimi = apply(matriceProbabilita, 1, which.max)

matches =0
for(k in 1:sampleNumber){
  if((vettoreIndiceMassimi[k]-1)==testSet[k,14])
    matches = matches+1
}
accuratezzaGlm[j] = matches/sampleNumber
```

Figura 12: Frammento di codice per il calcolo dell'accuratezza dei classificatori ottenuti tramite regressione logistica.

In particolare, matches contiene il numero di assegnazioni di classi indovinate e sampleNumber contiene il numero di righe che compongono il test set.
Per ottenere dei risultati significativi dal punto di vista statistico, effettuiamo la suddivisione del dataset in modo casuale in training set e test set 30 volte ed ogni volta costruiamo i classificatori e ne valutiamo l'accuratezza. Otteniamo che l'accuratezza media del modello ottenuto tramite analisi discriminante é del 72%, con una deviazione standard del 6%, mentre il classificatore ottenuto tramite regressione logistica ha un'accuratezza del 59%, con una deviazione standard del 6%. Possiamo quindi concludere che l'analisi discriminante é molto piú efficace della regressione logistica nella suddivisione dei brani per genere musicale.

4 Conclusioni

Come giá detto in precedenza, il modello che useremo per distinguere i generi musicali dei brani é quello ottenuto tramite analisi discriminante, in quanto ha un'accuratezza piú alta, a paritá di deviazione standard. Usando tale modello, un servizio di streaming musicale puó suggerire agli utenti le canzoni che fanno parte di quei generi musicali da loro preferiti (espressi in fase di registrazione al servizio), con un'accuratezza del 70% circa.
Bisogna comunque tenere presente che molte canzoni che sono state classificate in modo sbagliato dal classificatore ottenuto potrebbero avere caratteristiche che le rendano molto simili alla classe "sbagliata", pur essendo etichettate da Spotify come appartenenti ad un'altra classe. Questo per dire che l'accuratezza del modello potrebbe essere stata abbassata da alcuni brani che non appartengono ad un determinato genere, ma che invece sono fusioni di generi diversi.
Il risultato ottenuto é comunque buono e un futuro utilizzo di tale modello su servizi di streaming musicale non é da escludere.